实验一: 环境搭建

Design by W.H Huang | Direct by Prof Feng

1 实验目的

本次实验预估耗时较长,因此将给出所有详细步骤,如若不能及时完成可在课后完成。

通过本次实验, 你应该完成以下部分:

- 组内合作完成 Hadoop & Spark 单机版环境搭建
- 组内合作完成 Hadoop & Spark 分布式环境搭建

最终需搭建相关详细环境如下:

• 操作系统: centOS 7.6.64

● 图形界面: GNOME

• 语言环境: python 3.6.8

• 相关软件: Hadoop 2.8.5 、Spark 2.4.4

2 实验准备

本次实验将详细介绍三种方式来搭建 Hadoop & Sapak 分布式环境:

- 云服务器分布式搭建
- 伪分布式搭建
- 多台机器分布式搭建

考虑到大家 IP 是动态分配(DHCP), 没有使用固定IP。使用第三种方式 *多台实际机器搭建* 不方便。因此推荐大家使用前两种方式:云服务器分布式搭建、伪分布式搭建进行环境搭建。

3 云服务器分布式搭建

出于最简化演示目的,本次搭建将采用两台云服务器进行Hadoop+Spark 详细搭建记录。

○ 如果小组成员>2,分布式搭建过程大同小异聪明如你应该知道怎么做。

首先记录下小组组员各自服务器的 内网IP&公网IP,例如我的:

主机名	内网IP	外网IP
master	172.30.0.7	129.28.154.240
slave01	172.16.0.4	134.175.210.3

3.1 Spark单机版搭建

△ 请注意,③.1.1 部分需在小组成员在**所有**云服务器上完成。③.1.2~3.1.4 小节只需在一台云服务器完成即可(作为master节点那台服务器)。

在进行Hadoop、Spark环境搭建前,我们需要进行一些准备工作。

3.1.1 准备工作

1配置用户

该小节主要是创建 Hadoop 用户。

1. 创建用户

```
useradd -m hadoop -s /bin/bash
```

同时设置用户密码: (如 123456)

passwd hadoop

2. 配置权限

为了方便, 给用户 hadoop 等同 root 权限:

```
visudo # 执行 visudo命令进入vim编辑
```

找到如下位置,添加红框那一行配置权限:

```
## The COMMANDS section may have other options added to it.
##
## Allow root to run any commands anywhere
root ALL=(ALL) ALL
hadoop ALL=(ALL) ALL
```

3. 切换用户

配置完成后,我们切换到hadoop用户下:

```
su hadoop # 注意,不要使用root用户,以下全部切换到hadoop用户下操作
```

△ 如非特殊说明,接下来所有命令都是Hadoop用户下完成!

2 配置SSH

为什么要配置ssh?

因为集群、单节点模式都需要用到 ssh登陆。同时每次登陆ssh都要输入密码是件蛮麻烦的事 ,我可以通过生成公钥配置来面密码登陆。

1. 生成密钥

为了生成~/.ssh 目录,我们直接通过执行下面命令会直接生成

```
ssh localhost # 按提示输入yes,然后键入hadoop密码
```

然后开始生成密钥

```
cd ~/.ssh/ # 切换目录到ssh下
ssh-keygen -t rsa # 生成密钥
```

生成密钥过程会有三个提示,不用管全部回车。

2. 授权

```
cat id_rsa.pub >> authorized_keys # 加入授权
```

3. 修改权限

如果不修改文件 authorized_keys 权限为 600, 会出现访问拒绝情况

```
chmod 600 ./authorized_keys # 修改文件权限
```

4. 测试

```
ssh localhost # ssh登陆
```

不用输入密码,直接登陆成功则说明配置正确。

```
[hadoop@VM_0_7_centos .ssh]$ ssh localhost
Last login: Thu Jan 23 17:05:19 2020 from 127.0.0.1
```

3 配置yum源

官方网站下载实在太慢,我们可以先配置一下阿里源来进行下载。

1. 切换到 yum 仓库

```
cd /etc/yum.repos.d/
```

2. 备份下原repo文件

```
sudo mv CentOS-Base.repo CentOS-Base.repo.backup
```

3. 下载阿里云repo文件

```
sudo wget -0 /etc/yum.repos.d/CentOS-7.repo
http://mirrors.aliyun.com/repo/Centos-7.repo
```

防止权限不足使用 sudo 命令。

4. 设置为默认repo文件

就是把阿里云repo文件名修改为 CentOS-Base.repo

```
sudo mv CentOS-7.repo CentOS-Base.repo # 输入y
```

5. 生成缓存

```
yum clean all
yum makecache
```

4配置Java环境

最开始下载的是 1.7 版本的JDK,后面出现的问题,重新下载 1.8 版本 JDK。

hadoop2 基于 java 运行环境,所以我们先要配置java 运行环境。

1. 安装 JDK

执行下面命令,经过实际测试前面几分钟一直显示镜像错误不可用。它会进行自己尝试别的源,等 待一会儿就可以下载成功了。

```
sudo yum install java-1.8.0-openjdk java-1.8.0-openjdk-devel
```

⚠ 此时默认安装位置是 /usr/lib/jvm/java-1.8.0-openjdk

其实, 查找安装路径, 可以通过以下命令:

```
rpm -ql java-1.8.0-openjdk-devel | grep '/bin/javac'
```

- o rpm -q1 <RPM包名>: 查询指定RPM包包含的文件
- o grep <字符串>: 搜索包含指定字符的文件
- 2. 配置环境变量

```
vim ~/.bashrc # vim编辑配置文件
```

在文件最后面添加如下单独一行(指向 JDK 的安装位置),并保存:

export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk

```
# add chrome path
export PATH=$PATH:/opt/google/chrome
export JAVA_HOME=/usr/lib/jvm/java-1.7.0-openjdk
```

最后是环境变量生效,执行:

```
source ~/.bashrc
```

3. 测试

```
echo $JAVA_HOME # 检验变量值
```

正常会输出 2. 环境变量JDK配置路径。

```
java -version
```

正确配置会输出java版本号。

5 安装python

CentOS自带python2版本过低,我们进行python3安装。

1. yum查找python3

查找仓库存在的python3安装包

```
yum list python3
```

python3.x86_64 3.6.8-10.el7 @bas

2. yum 安装python3

```
sudo yum install python3.x86_64
```

如果最开始会显示没有,等一会自动切换阿里源就可以进行安装了, *同时还会安装相关依赖*。

3.1.2 hadoop 安装

本文使用 wget 命令来下载 hadoop : 了解更多wget

使用的是北理工镜像站,下载 hadoop:

Index of /apache/hadoop/common/hadoop-2.8.5

 Name
 Last modified
 Size
 Description

 Parent Directory

 hadoop-2.8.5-src.tar.gz
 2018-09-18 23:47
 34M

 hadoop-2.8.5.tar.gz
 2018-09-18 23:47
 235M

1. 下载

为防止证书验证出现的下载错误,加上 --no-check-certificate ,相关讨论可见 issue#1

```
sudo wget -0 hadoop-2.8.5.tar.gz
https://mirrors.cnnic.cn/apache/hadoop/common/hadoop-2.8.5/hadoop-
2.8.5.tar.gz --no-check-certificate
```

o wget -o <指定下载文件名> <下载地址>

2. 解压

```
sudo tar -zxf hadoop-2.8.5.tar.gz -C /usr/local
```

把下载好的文件 hadoop-2.8.5.tar.gz 解压到 /usr/local 目录下

3. 修改文件

```
cd /usr/local/ # 切換到解压目录下
sudo mv ./hadoop-2.8.5/ ./hadoop # 将加压的文件hadoop-2.8.5重命名为hadoop
sudo chown -R hadoop:hadoop ./hadoop # 修改文件权限
```

4. 测试

```
cd /usr/local/hadoop # 切换到hadoop目录下
./bin/hadoop version # 输出hadoop版本号
```

[hadoop@VM_0_7_centos hadoop]\$./bin/hadoop version Hadoop 2.8.5

3.1.3 spark安装

在前我们已经安装了 hadoop, 现在我们来开始进行spark 安装。

这次下载根据官网推荐使用的清华源。

1. 下载

官网下载地址: 官网下载

Download Apache Spark™

- 1. Choose a Spark release: 2.4.4 (Aug 30 2019) ▼
- 2. Choose a package type: Pre-built with user-provided Apache Hadoop
- 3. Download Spark: spark-2.4.4-bin-without-hadoop.tgz
- 4. Verify this release using the 2.4.4 signatures, checksums and project release KEYS.

。 这样选择的版本可以使用于大部分 hadoop 版本

点击上述链接,根据跳转的页面提示选择清华源下载:

注意,版本号可能发生变化,建议打开上述官网链接查看当前存在的版本。如我查看到只支持2.4.7版本(2020/09/17),那么需修改下面版本号:[2.4.4-->2.4.7]

```
sudo wget -O spark-2.4.7-bin-without-hadoop.tgz
http://mirrors.tuna.tsinghua.edu.cn/apache/spark/spark-2.4.7/spark-2.4.7-
bin-without-hadoop.tgz # 版本号发生变化,记得替换,下同
```

2. 解压

同前解压到 /usr/local 目录下

```
sudo tar -zxf spark-2.4.7-bin-without-hadoop.tgz -C /usr/local
```

3. 设置权限

```
cd /usr/local # 切換到解压目录
sudo mv ./spark-2.4.7-bin-without-hadoop ./spark # 重命名解压文件
sudo chown -R hadoop:hadoop ./spark # 设置用户hadoop为目录spark拥有者
```

4. 配置spark环境

先切换到 /usr/local/spark , (为了防止没权限, 下面用 sudo)

```
cd /usr/local/spark
cp ./conf/spark-env.sh.template ./conf/spark-env.sh
```

编辑 spark-env.sh 文件:

```
vim ./conf/spark-env.sh
```

在第一行添加下面配置信息,使得Spark可以从Hadoop读取数据。

```
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)
```

5. 配置环境变量

```
vim ~/.bashrc
```

在.bashrc 文件中添加如下内容:

```
export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk # 之前配置的java环境变量 export HADOOP_HOME=/usr/local/hadoop # hadoop安装位置 export SPARK_HOME=/usr/local/spark export PYTHONPATH=$SPARK_HOME/python:$SPARK_HOME/python/lib/py4j-0.10.7-src.zip:$PYTHONPATH export PYSPARK_PYTHON=python3 # 设置pyspark运行的python版本 export PATH=$HADOOP_HOME/bin:$SPARK_HOME/bin:$PATH
```

最后为了使得环境变量生效,执行:

```
source ~/.bashrc
```

6. 测试是否运行成功

```
cd /usr/local/spark
bin/run-example SparkPi
```

执行会输出很多信息,也可以选择执行:

```
bin/run-example SparkPi 2>&1 | grep "Pi is"
```

```
[hadoop@VM_0_7_centos spark]$ bin/run-example SparkPi 2>&1 | grep "Pi is"
Pi is roughly 3.1462557312786563
```

3.1.4 测试

1. 启动pyspark

```
cd /usr/local/spark
bin/pyspark
```

```
[hadoop@VM 0 7 centos spark]$ bin/pyspark

Python 3.6.8 (default, Aug 7 2019, 17:28:10)

[GCC 4.8.5 20150623 (Red Hat 4.8.5-39)] on linux

Type "help", "copyright", "credits" or "license" for more information.

20/01/23 17:33:19 WARN util.Utils: Your hostname, VM_0_7_centos resolves to a loopback add ress: 127.0.0.1; using 172.30.0.7 instead (on interface eth0)

20/01/23 17:33:19 WARN util.Utils: Set SPARK_LOCAL_IP if you need to bind to another addre ss

20/01/23 17:33:19 WARN util.NativeCodeLoader: Unable to load native-hadoop library for you r platform... using builtin-java classes where applicable Setting default log level to "WARN".

To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel). Welcome to
```

2. 简单测试

```
>>> 8 * 2 + 5
```

>>> 2019+1*1

使用 exit() 命令可退出。

3.2 Hadoop+Spark 分布式环境搭建

3.2.1 准备工作

1 修改主机名

两台服务器一台作为master,一台作为slave。为了以示区分,我们分别修改它们的主机名:

• 在master

```
sudo vim /etc/hostname
```

编辑修改为: master

• 在 slave01

sudo vim /etc/hostname

编辑修改为: slave01

最后使用命令 sudo reboot 重启, 便会生效。

2 修改host

修改hosts目的: 可以使用云服务器名字访问, 而不直接使用IP地址

首先上自己的云服务器,记录下三台服务器的 内网P&公网P

主机名	内网IP	外网IP
master	172.30.0.7	129.28.154.240
slave01	172.16.0.4	134.175.210.3

• 在master上

```
su hadoop
sudo vim /etc/hosts
```

编辑hosts文件如下(以前的全部删除,改成下面这样):

```
127.0.0.1 localhost
172.30.0.7 master # master必须用内网IP
134.175.210.3 slave01 # slave01用外网IP
```

• 在 slave 01上

```
su hadoop
sudo vim /etc/hosts
127.0.0.1 localhost
129.28.154.240 master # master必须用外网IP
172.16.0.4 slave01 # slave01用内网IP
```

3 SSH互相免密

在之前我们搭建Spark单机版环境时,我们配置ssh可以 无密码本地连接:

```
ssh localhost # 保证两台服务器都可以本地无密码登陆
```

现在我们还要让 <u>master 主机免密码登陆 slave01、slave02</u>。因此我们要将master主机的 id_rsa.pub 分别传递给两台slave主机。

1. 在 master 上scp传递公钥

第一次传要输入slave01@hadoop用户密码,例如之前设置为123456

```
scp ~/.ssh/id_rsa.pub hadoop@slave01:/home/hadoop/
```

2. 在slave01上加入验证

```
ls /home/hadoop/ # 查看master传送过来的 id_rsa.pub文件
```

将master公钥加入免验证:

```
cat /home/hadoop/id_rsa.pub >> ~/.ssh/authorized_keys
rm /home/hadoop/id_rsa.pub
```

3. 测试

现在我们切换到master主机上,尝试能否免密登陆:

```
[hadoop@master ~]$ ssh slave01
Last failed login: Thu Jan 23 17:44:52 CST 2020 from 129.28.154.240 on ssh:notty
There was 1 failed login attempt since the last successful login.
Last login: Thu Jan 23 17:44:31 2020 from 127.0.0.1
```

验证可以免密登陆后切换回master主机

```
ssh master # 要输入master@hadoop用户密码
```

3.2.2 Hadoop集群配置

原本我们需要同时在master和slave节点安装配置Hadoop集群,但是我们也可以通过仅配置master节点Hadoop,然后将整个配置好的Hadoop文件传递给各个子节点。

master节点配置

我们需要修改master主机上hadoop配置文件。

1. 切换目录

配置文件在 /usr/local/hadoop/etc/hadoop 目录下:

cd /usr/local/hadoop/etc/hadoop

```
[hadoop@master hadoop]$ ll
total 160
-rw-r--r-- 1 hadoop hadoop
```

2. 修改文件 slaves

master主机作为 NameNode ,而 slave01 作为 DataNode

```
vim slaves
```

修改如下:

```
slave01
```

3. 修改文件 core-site.xml

```
vim core-site.xml
```

4. 修改 hdfs-site.xml:

```
vim hdfs-site.xml
```

5. 修改 mapred-site.xml.template

△ 首先复制它产生一个新复制文件并命名为: mapred-site.xml

```
cp mapred-site.xml.template mapred-site.xml
```

然后修改文件 vim mapred-site.xml:

6. 修改 yarn-site.xml

slave节点配置

当然你也可以尝试在slave节点上重复一遍master节点上的配置,而非通过传送文件。

► 方法1: 通过scp将上述变动文件发送至slave (可以大幅度减少传送时间)

1. 传送已修改的配置文件

</configuration>

在master上节点上,使用如下命令将yarn-site.xml等发送到从机上。

```
# on master
scp /usr/local/hadoop/etc/hadoop/core-site.xml
hadoop@slave01:/usr/local/hadoop/etc/hadoop/
scp /usr/local/hadoop/etc/hadoop/hdfs-site.xml
hadoop@slave01:/usr/local/hadoop/etc/hadoop/
scp /usr/local/hadoop/etc/hadoop/mapred-site.xml
hadoop@slave01:/usr/local/hadoop/etc/hadoop/
scp /usr/local/hadoop/etc/hadoop/
scp /usr/local/hadoop/etc/hadoop/yarn-site.xml
hadoop@slave01:/usr/local/hadoop/etc/hadoop/
```

2. 检查文件变更

通过cat命令检查slave上的相关文件是否变更。

```
# on slave
cat /usr/local/hadoop/etc/hadoop/core-site.xml # 确认文件是否传送正确
```

输出中含有上一步中修改后的信息,则确认正确。比如,core-site.xml 文件输出如下:

▶ 方法2: 压缩拷贝整个hadoop目录

• 在master节点上执行

```
cd /usr/local/
rm -rf ./hadoop/tmp # 删除临时文件
rm -rf ./hadoop/logs/* # 删除日志文件
# 压缩./hadoop文件,并重名为hadoop.master.tar.gz
tar -zcf ~/hadoop.master.tar.gz ./hadoop
```

将压缩好的文件传递给 slave01:

```
cd ~
scp ./hadoop.master.tar.gz slave01:/home/hadoop
```

- ② 传递速度有点慢,大概要半小时。等待时间你可以先撰写部分实验报告,或者尝试浏览接下来实验步骤。
- 在slave01节点上

(如果有) 删除原有hadoop文件夹

```
sudo rm -rf /usr/local/hadoop/
```

解压传过来的文件到指定目录 /usr/local:

```
sudo tar -zxf /home/hadoop/hadoop.master.tar.gz -C /usr/local
```

设置解压出来的hadoop文件夹权限:

```
sudo chown -R hadoop /usr/local/hadoop
```

集群启动测试

1. master上启动集群

```
cd /usr/local/hadoop
bin/hdfs namenode -format  # 注意,仅在第一次启动集群时使用该命令格式化!
sbin/start-all.sh
```

2. 测试

o 在master上

```
jps
```

master节点出现以下4个进程则配置成功:

```
[hadoop@master hadoop]$ jps
13191 NameNode
13869 Jps
13598 ResourceManager
13438 SecondaryNameNode
```

。在slave01上

```
jps
```

slave节点出现以下3个进程则配置成功:

```
[hadoop@slave01 ~]$ jps
5384 DataNode
5689 Jps
5549 NodeManager
```

常见问题汇总

Q1: slave 节点没有 DataNode 进程 / master 节点没有 namenode 进程?

这个问题一般是由于在启动集群多次执行格式化命令:

```
bin/hdfs namenode -format
```

导致 hodoop 目录下 tmp/dfs/name/current 文件下的 VERSION 中的 namespaceId 不一致。

首先我们 在master 节点上停止集群:

```
cd /usr/local/hadoop # 切换到你的hadoop目录下
sbin/stop-all.sh # 关闭集群
```

• slave 节点删除 tmp

删除slave节点的临时 tmp 文件

```
cd /usr/local # 切換到hadoop目录
rm -rf ./hadoop/tmp
```

删除 tmp 文件,如法炮制在 其它节点进行一样的操作:

```
rm -rf ./hadoop/tmp # 后面格式化会重新生成,大胆删除
```

• 在master 节点删除 tmp

```
cd /usr/local
rm -rf ./hadoop/tmp
```

• 重新启动集群

在master节点执行以下操作:

```
cd /usr/local/hadoop
bin/hdfs namenode -format # 重新格式化
sbin/start-all.sh
```

• 验证

在 master 节点执行以下操作:

```
cd ~
jps
```

```
[root@master hadoop]# jps
30496 NameNode
30882 ResourceManager
30717 SecondaryNameNode
621 Master
32127 Jps
```

在子节点再次输入 jps 命令:

```
cd ~
jps
```

```
[root@slave02 ~]# jps
5794 Jps
5613 NodeManager
5503 DataNode
```

ok~

Q2: 启动集群后发现, Slave 节点没有 NodeManager 进程

```
[hadoop@slave01 local]$ jps
30673 DataNode
31172 Jps
```

△ 建议先尝试 Q1 方法, 一般能解决大部分问题。

启动集群时可以知道,启动 slave01 节点 notemanager 进程相关日志在 (最后不是 .out 是 .log)

/usr/local/hadoop/logs/yarn-hadoop-nodemanager-slave01.log

```
[hadoop@master hadoop]$ sbin/start-all.sh
This script is Deprecated. Instead use start-dfs.sh and start-yarn.sh
Starting namenodes on [master]
master: starting namenode, logging to /usr/local/hadoop/logs/hadoop-hadoop-namenode-master.out
slave01: starting datanode, logging to /usr/local/hadoop/logs/hadoop-hadoop-datanode-slave01.o
ut
Starting secondary namenodes [0.0.0.0]
0.0.0: starting secondarynamenode, logging to /usr/local/hadoop/logs/hadoop-hadoop-secondary
namenode-master.out
starting yarn daemons
starting resourcemanager, logging to /usr/local/hadoop/logs/yarn-hadoop-resourcemanager-master
.out
slave01: starting nodemanager,
logging to /usr/local/hadoop/logs/yarn-hadoop-nodemanager-slave
01.out
```

1. 查看日志

在 slave01 节点下

vim /usr/local/hadoop/logs/yarn-hadoop-nodemanager-slave01.log

日志太多,我们在命令模式下,输入:\$,直接跳到最后一行:

2020-01-31 18:12:33,973 INFO org.apache.hadoop.service.AbstractService: Service org.apache.hadoop.ya rn.server.nodemanager.containermanager.localizer.ResourceLocalizationService failed in state STARTED; cause: org.apache.hadoop.yarn.exceptions.YarnRuntimeException: java.net.BindException: Problem bin ding to [0.0.0.0:8040] java.net.BindException: Address already in use; For more details see: http://wiki.apache.org/hadoop/BindExceptions.YarnRuntimeException: java.net.BindException: Problem binding to [0.0.0.8040] java.net.BindException: Address already in use; For more details see: http://wiki.apache.org/hadoop/BindException
at org.apache.hadoop.yarn.factories.impl.pb.RpcServerFactoryPBImpl.getServer(RpcServerFactoryPBImpl.java:138)

- 很显然,显示端口 8040 被占用
- 2. 查看谁占用 8040 端口

```
netstat -tln | grep 8040
```

```
[hadoop@slave01 local]$ netstat -tln | grep 8040 tcp6 0 0 :::8040 :::* LISTEN
```

果然 8040 端口已经被占用

3. 释放端口

```
lsof -i :8040 # 查询占用8040端口进程pid
```

```
[hadoop@slave01 local]$ lsof -i :8040
COMMAND PID USER FD TYPE DEVICE SIZE/OFF NODE NAME
java 16961 hadoop 231u IPv6 38843230 0t0 TCP *:ampify (LISTEN)
```

杀死相应进程:

```
kill -9 16961
```

4. 测试

重新启动集群

```
cd /usr/local/hadoop
sbin/stop-all.sh
sbin/start-all.sh
```

再次输入 jps 命令,发现 slave01 节点 NodeManager 进程已经出现!

```
[hadoop@slave01 local]$ jps
30673 DataNode
6419 Jps
6035 NodeManager
```

3.2.3 Spark集群配置

以下步骤都建立在是我们三台云服务器已经搭建好Spark单机版环境 & hadoop集群。

Spark配置

1. 切换配置目录

```
cd /usr/local/spark/conf
```

2. 配置 slaves 文件

```
cp slaves.template slaves # 先把模板文件复制重命名
```

开始编辑 vim slaves,将默认内容 localhost 替换为以下:

```
slave01
```

3. 配置 spark-env.sh 文件

```
cp spark-env.sh.template spark-env.sh
```

开始编辑,添加下面内容:

```
vim spark-env.sh
```

```
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)
export HADOOP_CONF_DIR=/usr/local/hadoop/etc/hadoop
export SPARK_MASTER_IP=172.30.0.7 # 注意,使用的master内网IP!!
```

4. 复制Spark文件到各个slave节点

```
cd /usr/local/
tar -zcf ~/spark.master.tar.gz ./spark
cd ~
scp ./spark.master.tar.gz slave01:/home/hadoop
```

5. 节点替换文件

以下操作是在 slave节点上:

```
sudo rm -rf /usr/local/spark/ # 删除节点原有Spark文件(如果有)
sudo tar -zxf /home/hadoop/spark.master.tar.gz -C /usr/local # 解压到local
sudo chown -R hadoop /usr/local/spark # 设置spark文件权限拥有者是hadoop
```

启动Spark集群

在master主机上执行以下操作

1. 先启动hadoop集群

```
cd /usr/local/hadoop/
sbin/start-all.sh
```

2. 启动master节点

```
cd /usr/local/spark/
sbin/start-master.sh
```

master上运行 jps 命令可以看到:

```
[hadoop@master spark]$ jps
18160 Master
18224 Jps
13191 NameNode
13598 ResourceManager
13438 SecondaryNameNode
```

3. 启动所有slave节点

```
sbin/start-slaves.sh
```

slave节点上运行 jps 命令可以看到:

```
[hadoop@slave01 ~]$ jps
9527 Jps
5384 DataNode
5549 NodeManager
9471 Worker
```

4. web UI查看

在浏览器上输入: master: 8080 ,如果出现下面界面则表示 Hadoop+Spark 分布式环境搭建成功!

如果前面一切正常, Web UI 却无法正常正常显示worker, 请尝试:

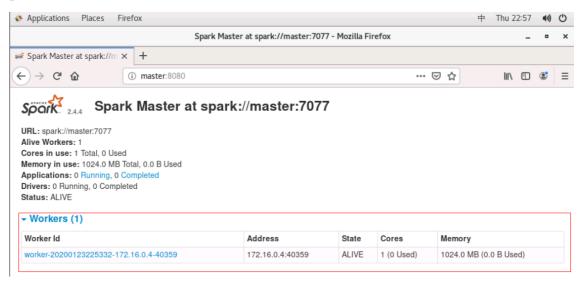
- 1. 参考 issue#3 @trevery
 - 关闭集群,重启启动集群,执行如下start-slave命令并输入相关参数(不是运行start-slaves.sh)

sbin/start-slave.sh spark://localhost:7077

■ 或者将localhost换成内网ip (不一定可行)

sbin/start-slave.sh spark://<master内网ip>:7077 # 替换<master内网ip> 为你的master内网ip

- 2. 参考 issue#8 @iDream-G



🤌 🕭 聪明如你终于做到这步了,第一个实验完结,撒花 🦫 🤌

4 伪分布式搭建

① 选择伪分布式搭建的同学,**每一个组员**都需要在各自服务器上**独立完成**环境搭建。

4.1 Spark单机版搭建

在进行Hadoop、Spark环境搭建前,我们需要进行一些准备工作。

4.1.1 准备工作

1配置用户

该小节主要是创建 Hadoop 用户。

1. 创建用户

```
useradd -m hadoop -s /bin/bash
```

同时设置用户密码: (如 123456)

passwd hadoop

2. 配置权限

为了方便, 给用户 hadoop 等同 root 权限:

```
visudo # 执行 visudo命令进入vim编辑
```

找到如下位置,添加红框那一行配置权限:

```
## The COMMANDS section may have other options added to it.
##
## Allow root to run any commands anywhere
root ALL=(ALL) ALL
hadoop ALL=(ALL) ALL
```

3. 切换用户

配置完成好,我们切换到hadoop用户下:

```
su hadoop
```

△ 如非特殊说明,接下来所有命令都是Hadoop用户下完成!

2 配置SSH

为什么要配置ssh?

因为集群、单节点模式都需要用到 ssh登陆。同时每次登陆ssh都要输入密码是件蛮麻烦的事 ,我可以通过生成公钥配置来面密码登陆。

1. 生成密钥

为了生成~/.ssh 目录,我们直接通过执行下面命令会直接生成

```
ssh localhost # 按提示输入yes,然后键入hadoop密码
```

然后开始生成密钥

```
cd ~/.ssh/# 切换目录到ssh下ssh-keygen -t rsa# 生成密钥
```

生成密钥过程会有三个提示,不用管全部回车。

2. 授权

```
cat id_rsa.pub >> authorized_keys # 加入授权
```

3. 修改权限

如果不修改文件 authorized_keys 权限为 600, 会出现访问拒绝情况

```
chmod 600 ./authorized_keys # 修改文件权限
```

4. 测试

```
ssh localhost # ssh登陆
```

不用输入密码,直接登陆成功则说明配置正确。

```
[hadoop@huang .ssh]$ ssh localhost
Last login: Fri Jan 24 11:16:06 2020 from 127.0.0.1
```

3 配置yum源

官方网站下载实在太慢,我们可以先配置一下阿里源来进行下载。

1. 切换到 yum 仓库

```
cd /etc/yum.repos.d/
```

2. 备份下原repo文件

```
sudo mv CentOS-Base.repo.backup
```

3. 下载阿里云repo文件

```
sudo wget -0 /etc/yum.repos.d/CentOS-7.repo
http://mirrors.aliyun.com/repo/Centos-7.repo
```

防止权限不足使用 sudo 命令。

4. 设置为默认repo文件

就是把阿里云repo文件名修改为 CentOS-Base.repo

```
sudo mv CentOS-7.repo CentOS-Base.repo # 输入y
```

5. 生成缓存

```
yum clean all
yum makecache
```

4配置Java环境

最开始下载的是 1.7 版本的JDK,后面出现的问题,重新下载 1.8 版本 JDK。

hadoop2 基于 java 运行环境,所以我们先要配置java 运行环境。

1. 安装 JDK

执行下面命令,经过实际测试前面几分钟一直显示镜像错误不可用。它会进行自己尝试别的源,等待一会儿就可以下载成功了。

```
sudo yum install java-1.8.0-openjdk java-1.8.0-openjdk-devel
```

△ 此时默认安装位置是 /usr/lib/jvm/java-1.8.0-openjdk

其实, 查找安装路径, 可以通过以下命令:

```
rpm -ql java-1.8.0-openjdk-devel | grep '/bin/javac'
```

- o rpm -q1 <RPM包名>: 查询指定RPM包包含的文件
- o grep <字符串>: 搜索包含指定字符的文件
- 2. 配置环境变量

```
vim ~/.bashrc # vim编辑配置文件
```

在文件最后面添加如下单独一行(指向 JDK 的安装位置),并保存:

```
export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk
```

```
# add chrome path
export PATH=$PATH:/opt/google/chrome
export JAVA_HOME=/usr/lib/jvm/java-1.7.0-openjdk
```

最后是环境变量生效,执行:

```
source ~/.bashrc
```

3. 测试

```
echo $JAVA_HOME # 检验变量值
```

正常会输出 2. 环境变量JDK配置路径。

```
java -version
```

正确配置会输出java版本号。

5 安装python

CentOS自带python2版本过低,我们进行python3安装。

1. yum查找python3

查找仓库存在的python3安装包

```
yum list python3
```

python3.x86_64 3.6.8-10.el7 @bas

2. yum 安装python3

```
sudo yum install python3.x86_64
```

如果最开始会显示没有,等一会自动切换阿里源就可以进行安装了,*同时还会安装相关依赖*。

4.1.2 hadoop 安装

本文使用 wget 命令来下载 hadoop : 了解更多wget

使用的是北理工镜像站,下载 hadoop:

Index of /apache/hadoop/common/hadoop-2.8.5

 Name
 Last modified
 Size
 Description

 → Parent Directory

 hadoop-2.8.5-src.tar.gz
 2018-09-18 23:47
 34M

 hadoop-2.8.5.tar.gz
 2018-09-18 23:47
 235M

1. 下载

为防止证书验证出现的下载错误,加上 --no-check-certificate ,相关讨论可见 issue#1

```
sudo wget -0 hadoop-2.8.5.tar.gz
https://mirrors.cnnic.cn/apache/hadoop/common/hadoop-2.8.5/hadoop-
2.8.5.tar.gz --no-check-certificate
```

o wget -o <指定下载文件名> <下载地址>

2. 解压

```
sudo tar -zxf hadoop-2.8.5.tar.gz -C /usr/local
```

把下载好的文件 hadoop-2.8.5.tar.gz 解压到 /usr/local 目录下

3. 修改文件

```
cd /usr/local/ # 切换到解压目录下
sudo mv ./hadoop-2.8.5/ ./hadoop # 将加压的文件hadoop-2.8.5重命名为hadoop
sudo chown -R hadoop:hadoop ./hadoop # 修改文件权限
```

4. 测试

```
cd /usr/local/hadoop # 切換到hadoop目录下
./bin/hadoop version # 输出hadoop版本号
```

```
[hadoop@huang hadoop]$ ./bin/hadoop version
Hadoop 2.8.5
Subversion https://git-wip-us.apache.org/repos/asf/hadoop.git -r 0b8464d75227fcee2c6e7f2410377b3d5
3d3d5f8
```

4.1.3 spark安装

在前我们已经安装了 hadoop , 现在我们来开始进行spark 安装。

这次下载根据官网推荐使用的清华源。

1. 下载

官网下载地址: 官网下载

Download Apache Spark™

- 1. Choose a Spark release: 2.4.4 (Aug 30 2019)
- 2. Choose a package type: Pre-built with user-provided Apache Hadoop
- 3. Download Spark: spark-2.4.4-bin-without-hadoop.tgz
- 4. Verify this release using the 2.4.4 signatures, checksums and project release KEYS.
- 。 这样选择的版本可以使用于大部分 hadoop 版本

点击上述链接,根据跳转的页面提示选择清华源下载:

注意,版本号可能发生变化,建议打开上述官网链接查看当前存在的版本。如我查看到只支持2.4.7版本(2020/09/17),那么需修改下面版本号: 2.4.4-->2.4.7

•

```
sudo wget -O spark-2.4.7-bin-without-hadoop.tgz
http://mirrors.tuna.tsinghua.edu.cn/apache/spark/spark-2.4.7/spark-2.4.7-
bin-without-hadoop.tgz # 版本号发生变化记得替换,下同
```

2. 解压

同前解压到 /usr/local 目录下

```
sudo tar -zxf spark-2.4.7-bin-without-hadoop.tgz -C /usr/local
```

3. 设置权限

```
cd /usr/local # 切换到解压目录
sudo mv ./spark-2.4.7-bin-without-hadoop ./spark # 重命名解压文件
sudo chown -R hadoop:hadoop ./spark # 设置用户hadoop为目录spark拥有者
```

4. 配置spark环境

先切换到 /usr/local/spark , (为了防止没权限, 下面用 sudo)

```
cd /usr/local/spark
cp ./conf/spark-env.sh.template ./conf/spark-env.sh
```

编辑 spark-env.sh 文件:

```
vim ./conf/spark-env.sh
```

在第一行添加下面配置信息,使得Spark可以从Hadoop读取数据。

```
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)
```

5. 配置环境变量

```
vim ~/.bashrc
```

在.bashrc 文件中添加如下内容:

```
export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk # 之前配置的java环境变量 export HADOOP_HOME=/usr/local/hadoop # hadoop安装位置 export SPARK_HOME=/usr/local/spark export PYTHONPATH=$SPARK_HOME/python:$SPARK_HOME/python/lib/py4j-0.10.7-src.zip:$PYTHONPATH export PYSPARK_PYTHON=python3 # 设置pyspark运行的python版本 export PATH=$HADOOP_HOME/bin:$SPARK_HOME/bin:$PATH
```

最后为了使得环境变量生效,执行:

```
source ~/.bashrc
```

6. 测试是否运行成功

```
cd /usr/local/spark
bin/run-example SparkPi
```

执行会输出很多信息,也可以选择执行:

```
bin/run-example SparkPi 2>&1 | grep "Pi is"
```

```
[hadoop@huang spark]$ bin/run-example SparkPi 2>&1 | grep "Pi is"
Pi is roughly 3.135315676578383
```

4.1.4 测试

1. 启动pyspark

```
cd /usr/local/spark
bin/pyspark
```

2. 简单测试

```
>>> 8 * 2 + 5
```

```
>>> 2019+1*1
2020
```

使用 exit() 命令可退出。

4.2 Hadoop+Spark 分布式环境搭建

4.2.1 Hadoop集群配置

Hadoop文件配置

我们需要修改hadoop配置文件。

1. 切换目录

配置文件在 /usr/local/hadoop/etc/hadoop 目录下:

cd /usr/local/hadoop/etc/hadoop

```
[hadoop@master hadoop]$ ll
total 160
-rw-r--r- 1 hadoop hadoop
```

2. 修改文件 core-site.xml

```
vim core-site.xml
```

△ 实际测试必须要 hdfs://0.0.0.0:9000 才能使用 hdfs 服务。

△ 有可能依旧报错: Error JAVA_HOME is not set and could not be found -

o 配置 hadoop-env.sh

```
cd /usr/local/hadoop/etc/hadoop
vim hadoop-env.sh
```

配置 JAVA_HOME 路径如下:

```
# The java implementation to use.
export JAVA_HOME=<mark>/usr/lib/jvm/java-1.8.0-openjdk</mark>
```

3. 修改 hdfs-site.xml:

```
vim hdfs-site.xml
```

集群启动测试

1. 启动集群

```
cd /usr/local/hadoop
bin/hdfs namenode -format # 注意,仅在第一次启动集群时使用该命令格式化!
sbin/start-all.sh
```

2. 测试

```
jps
```

出现以下6个进程则配置成功:

```
[hadoop@huang hadoop]$ jps
3024 DataNode
3184 SecondaryNameNode
3729 Jps
3331 ResourceManager
3431 NodeManager
2895 NameNode
```

4.2.2 Spark集群配置

Spark配置

1. 切换配置目录

```
cd /usr/local/spark/conf
```

2. 配置 spark-env.sh 文件

```
cp spark-env.sh.template spark-env.sh
```

开始编辑,添加下面内容:

```
vim spark-env.sh
```

```
export SPARK_DIST_CLASSPATH=$(/usr/local/hadoop/bin/hadoop classpath)
export HADOOP_CONF_DIR=/usr/local/hadoop/etc/hadoop
export SPARK_MASTER_IP=localhost
```

启动Spark集群

执行以下操作

1. 先启动hadoop集群

```
cd /usr/local/hadoop/
sbin/start-all.sh
```

2. 启动spark集群

```
cd /usr/local/spark/
sbin/start-all.sh
```

运行 jps 命令可以看到:

```
[root@huang ~]# jps
3024 DataNode
3184 SecondaryNameNode
3331 ResourceManager
3909 Worker
23798 Jps
3431 NodeManager
3770 Master
```

3. web UI查看

在浏览器上输入: [localhost: 8080] ,如果出现下面界面则表示 *Hadoop+Spark* 分布式环境搭建成功!

如果前面一切正常, Web UI 却无法正常正常显示worker, 请尝试:

- 1. 参考 <u>issue#3 @trevery</u>
 - 关闭集群,重启启动集群,执行如下start-slave命令并输入相关参数(不是运行start-slaves.sh)

```
sbin/start-slave.sh spark://localhost:7077
```

■ 或者将localhost换成内网ip (不一定可行)

```
sbin/start-slave.sh spark://<master内网ip>:7077 # 替换<master内网ip> 为你的master内网ip
```

- 2. 参考 issue#8 @iDream-G

